

# CLASSIFICATION AUTOMATIQUE DE TEXTES MÉDICAUX UTILISANT NLP



Encadreur: DR. Boustil Amel | Examineur: Dr. Touazi Fayçal | Licence informatique:2025/2026  
Narimane Tair | Benkaci ali Doua | Chikhi Aya | Meddahi Idir

## INTRODUCTION


Les maladies rares sont difficiles à identifier en raison de la complexité des données médicales. Cette étude propose une approche basée sur l'intelligence artificielle et le traitement automatique du langage naturel (NLP), combinant des embeddings biomédicaux, la recherche par similarité et les grands modèles de langage (LLM), afin d'identifier plus efficacement la maladie rare la plus probable et d'aider les professionnels de santé dans le processus diagnostique.

### Problématique

Comment améliorer la classification automatique des textes médicaux liés aux maladies rares malgré la faiblesse des données médicales disponibles ?

## DONNÉES UTILISÉES

### ① Dataset — RareArena

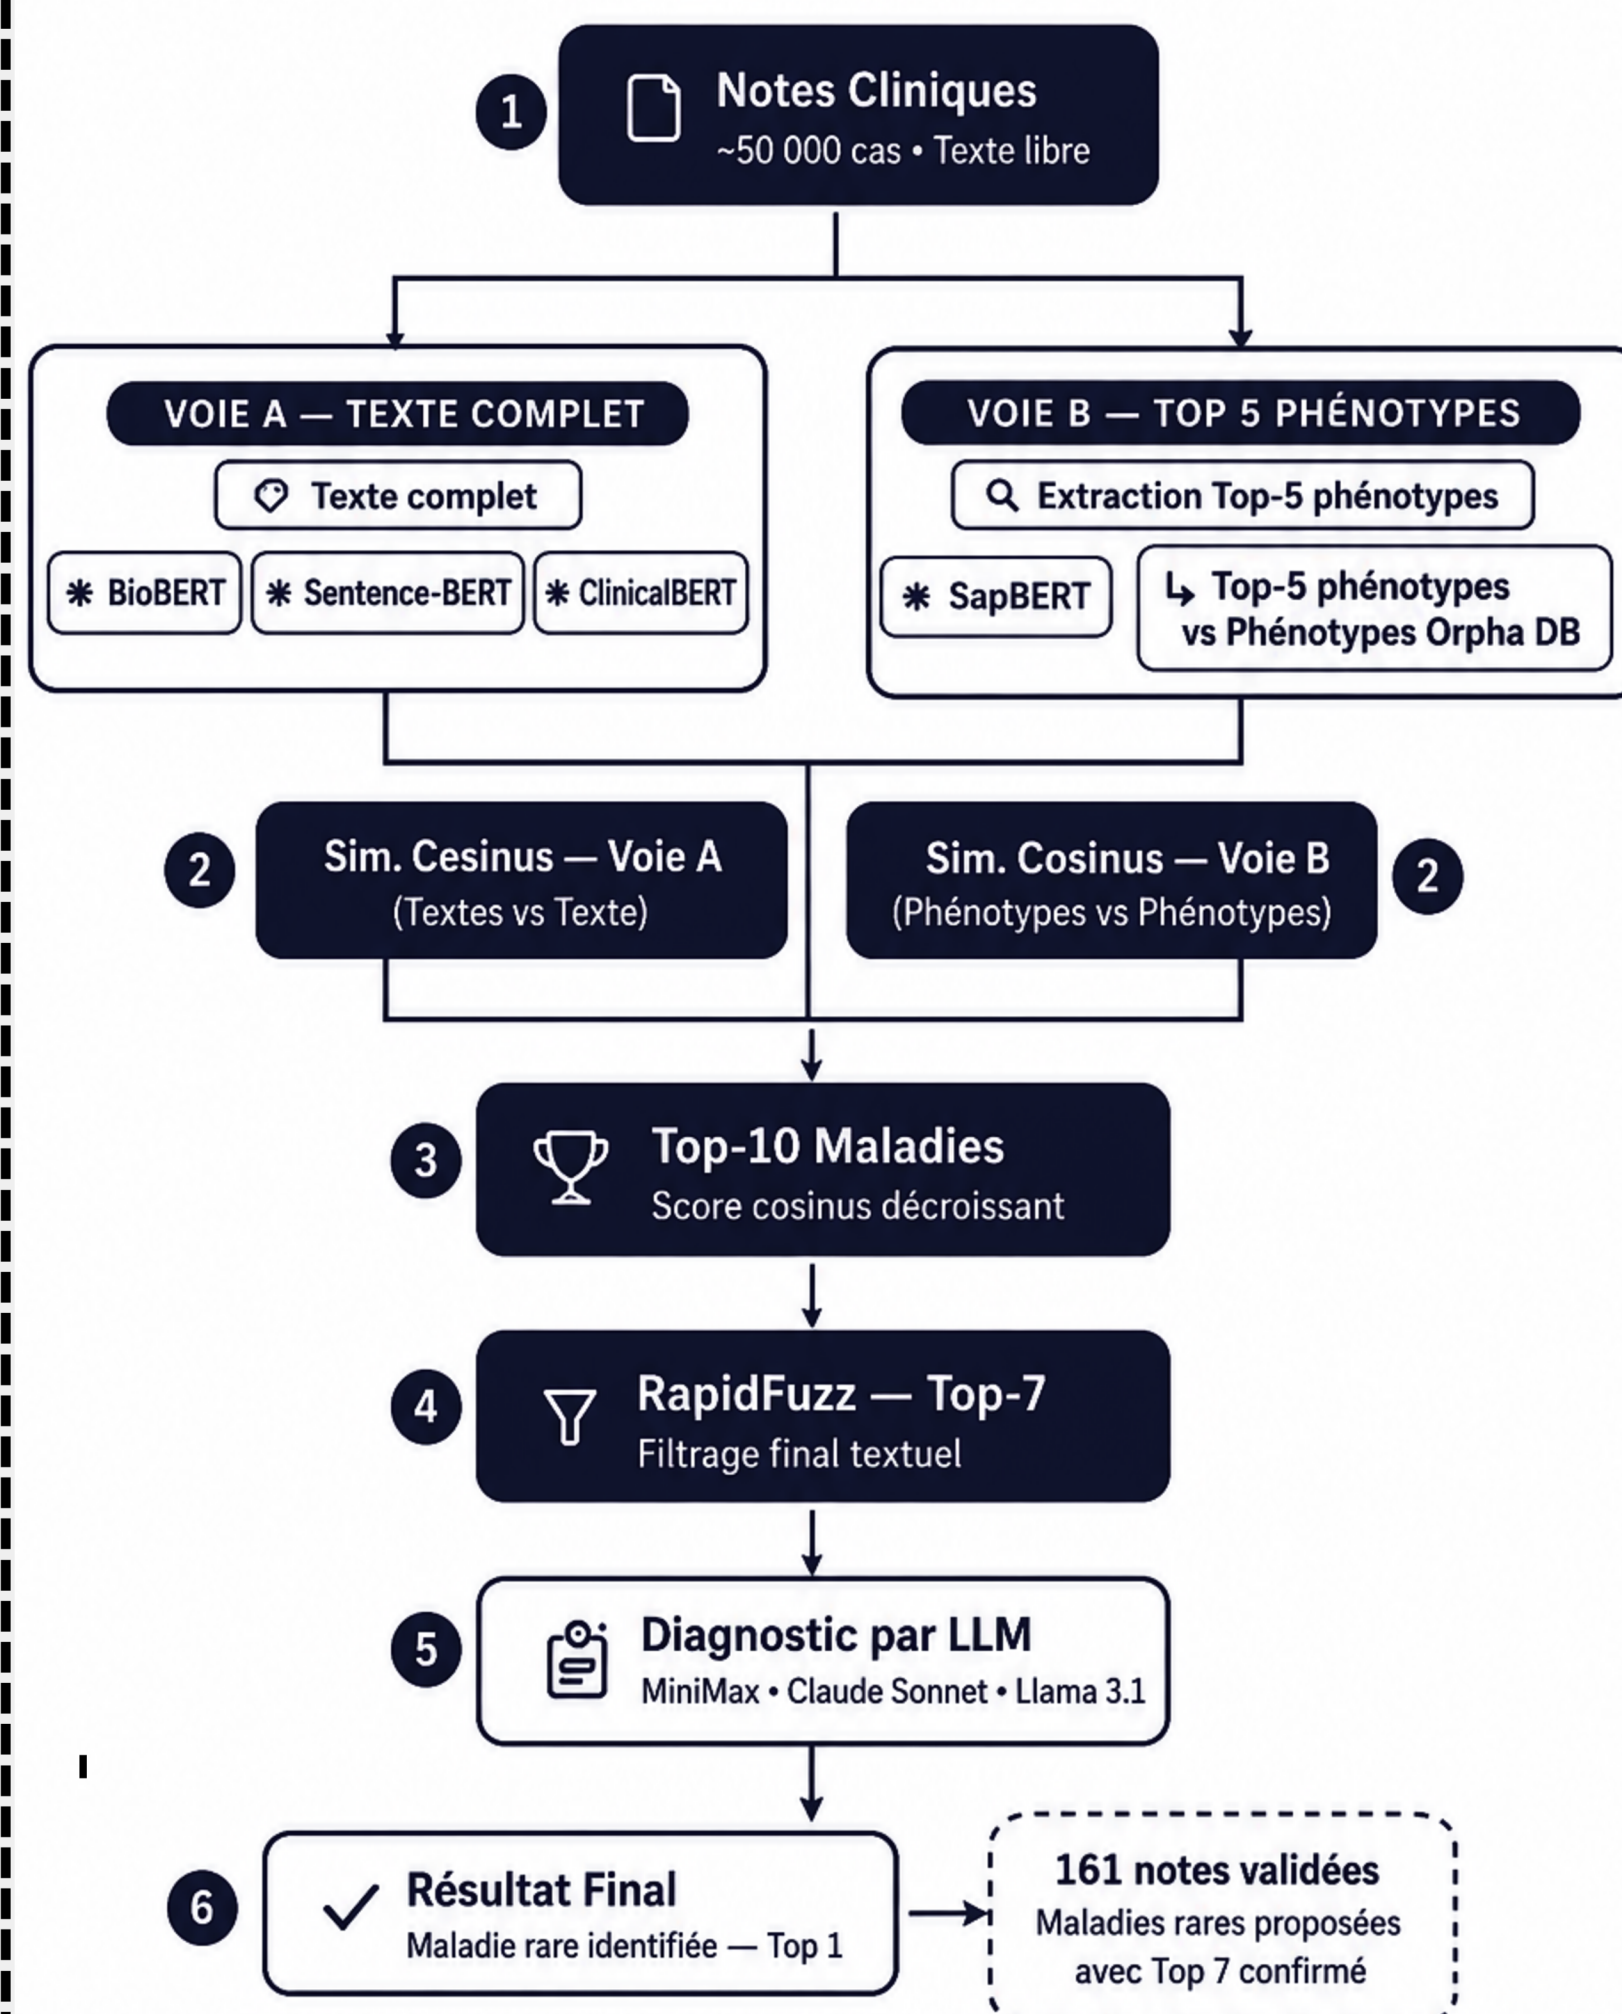


### ② Base de Connaissances



## Pipeline de Méthodologie — Diagnostic de Maladies Rares

BioBERT • Sentence-BERT • ClinicalBERT • SapBERT • Similarité Cosinus • RapidFuzz • LLM



## PIPELINE DE DIAGNOSTIC DES MALADIES RARES

**Approche 1 :** Notes cliniques complètes encodées (BioBERT, Sentence-BERT, ClinicalBERT) → similarité cosinus → Top-10 maladies candidates

**Approche 2 :** Phénotypes extraits des notes cliniques encodés avec SapBERT → comparaison aux phénotypes Orphanet → Top-10 maladies candidates

**Affinement :** Résultats affinés par RapidFuzz → sélection des maladies les plus pertinentes

**Diagnostic final :** Llama 3.1

### prompt naïf utilisé pour le diagnostic des maladies rares par LLM

```
def load_jsonl(path):
    with path.open("r", encoding="utf-8") as f:
        return [json.loads(line) for line in f if line.strip()]

def prompt_model(note):
    prompt = f"""Read the clinical note and name the single most likely rare disease

Rules:
- Output only the disease name.
- Do not explain.
- Do not list alternatives.
```

```
Clinical note:
{note}
"""
```

### Prompt structuré utilisé pour le raisonnement diagnostique du modèle Llama 3.1

```
prompt = f"""
You are a medical expert in rare diseases.

Clinical note:
{note}

Candidate diseases:
{diseases_text}

Task:
Choose exactly one disease from the candidate dideades that best matches the clinical note.
Return the selected disease name and its ORPHA ID exactly as shown in the candidate list.

Output:
Disease: ...
ORPHA: ...
Reason: ...
"""
```

## EXEMPLES DES RÉSULTATS

### 1. TOP 10 DIAGNOSTIC (SAPBERT)

| Rang | ORPHA ID     | Maladie                            | Score  |
|------|--------------|------------------------------------|--------|
| 1    | ORPHA:136    | Cerebral autosomal arteriopathy    | 0.6843 |
| 2    | ORPHA:727    | Microscopic polyangiitis           | 0.6842 |
| 3    | ORPHA:820    | Sneddon syndrome                   | 0.6755 |
| 4    | ORPHA:183675 | Recurrent demyelinating neuropathy | 0.6720 |
| 5    | ORPHA:80     | Antiphospholipid syndrome (Vraie)  | 0.6714 |
| 6    | ORPHA:1478   | Interatrial communication          | 0.6691 |
| 7    | ORPHA:26137  | Juvenile temporal arteritis        | 0.6656 |
| 8    | ORPHA:3287   | Takayasu arteritis                 | 0.6655 |
| 9    | ORPHA:206572 | Overlap myositis                   | 0.6625 |
| 10   | ORPHA:464343 | Catastrophic APS                   | 0.6599 |

### 2. EXEMPLE LLM & PERFORMANCES

| Modèle    | Réponse                        | ORPHA | Accuracy | F1-Score |
|-----------|--------------------------------|-------|----------|----------|
| Llama 3.1 | Thiel■Behnke corneal dystrophy | 98960 | 70.8%    | 0.547    |

### 3. COMPARATIF DES MODÈLES

| Modèle            | Approche     | Top-K  | Accuracy |
|-------------------|--------------|--------|----------|
| Sentence-BERT     | Embedding    | Top-10 | 0.002    |
| ClinicalBERT      | Embedding    | Top-10 | 0.02     |
| RapidFuzz         | Filtrage     | Top-7  | 0.018    |
| Claude Sonnet 4.5 | LLM Naïf     | Top-1  | 0.18     |
| Llama 3.1         | LLM Amélioré | Top-1  | 0.708    |

### 4. LIMITES & DISCUSSION

| Problème       | Description                                     |
|----------------|-------------------------------------------------|
| Déséquilibre   | Distribution inégale des maladies rares         |
| Variabilité    | Symptômes très différents pour une même maladie |
| Ressources     | Manque de GPU, ~50k notes disponibles           |
| Hallucinations | Erreurs de classification des modèles naïfs     |

### 5. PERSPECTIVES

| Perspective | Description                           |
|-------------|---------------------------------------|
| RAG         | Retrieval-Augmented Generation        |
| Fine-tuning | Réentraînement biomédical             |
| Ontologies  | Orphanet, MeSH                        |
| Multilingue | Extension à des datasets multilingues |

## CONCLUSION

La combinaison des embeddings biomédicaux et de Llama 3.1 améliore la classification des maladies rares, avec une accuracy de **70,8 %** obtenue par Llama 3.1 + RapidFuzz